

Universidad de San Andrés

Maestría en Economía



Universidad de
SanAndrés

Trabajo Práctico 4

Un instrumento que suena raro

Economía Aplicada

Prof. Martín Rossi

Santiago Reymondes

1. Un instrumento que suena raro

La ecuación estructural del paper es

$$\Delta y_{jd} = \alpha_1 + \alpha_2 \Delta T_{jd} + X_{jd0} \beta + \lambda_d + (\delta_j + \Delta \varepsilon_{jd}), \quad (1)$$

donde las piezas centrales son dos:

- ΔT_{jd} , un indicador de si la comunidad j del distrito d recibió un proyecto de Eskom entre 1996 y 2001, que es el regresor cuyo efecto causal queremos estimar.
- $\delta_j + \Delta \varepsilon_{jd}$, el término no observado, que contiene todo lo que afecta al cambio en el empleo y que no está capturado por los controles ni por los efectos fijos.

El resto son controles de línea de base (X_{jd0}) y efectos fijos de distrito (λ_d) que absorben diferencias promedio entre mercados laborales locales.

Lo que nos interesa estimar es α_2 , el **efecto de electrificar una comunidad sobre el cambio en su tasa de empleo**. Y acá aparece el problema: MCO sobre esta ecuación va a dar un $\hat{\alpha}_2$ sesgado, porque la asignación del tratamiento no fue aleatoria. Eskom priorizaba comunidades planas, densas y cercanas a la red eléctrica preexistente, porque ahí el costo por conexión era menor, pero la red preexistente se había construido durante el apartheid para servir a granjas comerciales, minas y pueblos blancos. Entonces las comunidades que Eskom electrifica primero son las que estaban geográficamente pegadas a los sectores de la economía comercial que se contraían durante los 90, y esa exposición al colapso comercial afecta el cambio en el empleo y queda metida en el término no observado, moviéndose junto con ΔT_{jd} .

La dirección del sesgo entonces va en un sentido específico: donde hay proyecto, el shock al empleo tiende a ser negativo por razones ajenas a la electricidad, y MCO subestima el efecto de electrificar. La Tabla 2 del paper muestra esta lógica, porque en zonas con proyecto el empleo masculino cae 5 puntos porcentuales mientras que en zonas sin proyecto cae 3.3, y esa diferencia de $-1,7$ puntos no es el efecto causal sino la presencia de sesgo.

Frente a este problema de endogeneidad, la autora recurre a variables instrumentales. La idea es encontrar una variable Z_j que mueva a ΔT_{jd} pero que no afecte por sí sola al empleo, y usar solo esa parte de la variación en el tratamiento para estimar α_2 . En este paper, Z_j es **la pendiente promedio del terreno de la comunidad**, y la primera etapa queda

$$\Delta T_{jd} = \pi_0 + \pi_1 Z_j + X_{jd0} \pi_2 + \gamma_d + \tau_{jd}. \quad (2)$$

Para que Z_j sirva como instrumento válido, tiene que cumplir dos condiciones:

- **Relevancia:** $\pi_1 \neq 0$, es decir, **la pendiente tiene que predecir efectivamente la asignación del tratamiento**. Este supuesto responde a una lógica tecnológica, porque tender líneas es más caro en terreno empinado (suelo más duro, más postes, valles y colinas) y Eskom prioriza lo plano. Se comprueba directamente con los datos en la Tabla 3 del paper.
- **Exclusión:** $\text{Cov}(Z_j, \delta_j + \Delta \varepsilon_{jd} \mid X_{jd0}, \lambda_d) = 0$, es decir, **la pendiente no puede afectar al cambio en el empleo por ninguna vía que no pase por el tratamiento**. Este supuesto

no se testea con datos, es un argumento teórico sobre el contexto. En este caso concreto dice que, condicional a los controles y a los efectos fijos, la pendiente del terreno no afecta el cambio en el empleo salvo a través de haber recibido un proyecto de Eskom.

La historia alternativa más clara que puede violar este supuesto va por el canal de las rutas. **Las comunidades más planas tienen mejor acceso a rutas y por lo tanto menores costos de transporte hacia mercados laborales fuera de la comunidad**, de modo que un habitante de una zona plana puede viajar más barato al pueblo cercano a trabajar en servicios o comercio. Bajo esta historia la pendiente afectaría el cambio en el empleo por el canal de la accesibilidad y no por la electricidad, con el trabajador que hace commuting como actor y el costo de transporte como mecanismo, y el efecto sobre Δy_{jd} sería positivo aunque no haya proyecto de Eskom en el medio. Si esta historia es cierta, Z_j viola exclusión y el MC2E no identifica el efecto de electrificar.

2. Las dos figuras

Presento las dos figuras que pide el enunciado, cada una construida como binscatter con 20 ventiles de pendiente. La primera muestra la primera etapa en sus dos versiones, cruda y residualizada, mientras que la segunda muestra la forma reducida, con cuatro paneles que combinan mujeres y varones en ambas versiones. La residualización aplica Frisch-Waugh-Lovell y absorbe los controles del paper junto con los efectos fijos de distrito, de manera que los residuos representan la variación que efectivamente identifica el efecto MC2E de la sección siguiente.




Figura 1: Primera etapa: fracción de comunidades con proyecto de Eskom contra pendiente.

En crudo (panel a), la fracción con proyecto cae de 0,30 a 0,12 cuando la pendiente pasa de 0 a 20 grados, con pendiente negativa fuerte y clara. Al residualizar (panel b), el rango vertical se comprime (los puntos ahora oscilan entre 0,13 y 0,25) pero la pendiente negativa se mantiene visible. La compresión indica que buena parte de la variación de la pendiente vive entre distritos, pero la señal que queda dentro de los distritos alcanza para identificar la primera etapa.




Figura 2: Forma reducida: cambio en la tasa de empleo entre 1996 y 2001 contra pendiente, por sexo.

Para mujeres (paneles a y b) la relación cruda es prácticamente plana y ruidosa, pero **al residualizar aparece una pendiente negativa nítida: los controles y los efectos fijos tapaban la señal en lugar de inflarla**. Para varones (paneles c y d) el patrón es distinto: la versión cruda muestra incluso una leve tendencia positiva, incompatible con la hipótesis causal, y al residualizar la relación se aplana casi por completo. La ausencia de forma reducida para varones anticipa que el estimador MC2E masculino del ejercicio siguiente va a resultar grande pero impreciso.

Volviendo a las preguntas del enunciado: la variación que usa el estimador se ve a ojo sobre todo en la primera etapa, y también en la forma reducida de mujeres una vez residualizada. El contraste entre paneles crudos y residualizados dice que la pendiente varía más entre distritos que dentro, pero deja variación intra-distrito suficiente para identificar el efecto. Y para varones no hay señal en ninguna de las dos versiones, lo que ya nos ubica en el resultado que vamos a ver en el ejercicio 3.

3. La tabla

Los resultados para mujeres y varones aparecen en los Cuadros 1 y 2, ambos con la especificación del paper (controles de línea de base, efectos fijos de distrito y errores agrupados por subdistrito). Los coeficientes replican al paper: MCO da $-0,001$ y MC2E da $0,095$ para mujeres, coincidiendo con

las columnas 4 y 8 de la Tabla 4, y la primera etapa da $-0,077$ como en la columna 4 de la Tabla 3.

Cuadro 1: Empleo femenino: MCO, primera etapa, forma reducida y MC2E.

	(1) MCO	(2) Primera etapa	(3) Forma reducida	(4) MC2E
=1 si recibió un proyecto de Eskom entre 1996 y 2001	-0.001 (0.005)			0.095* (0.055)
grad10		-0.077*** (0.027)	-0.007** (0.003)	
N	1816	1816	1816	1816
F efectivo (MOP)				8.26

Cuadro 2: Empleo masculino: MCO, primera etapa, forma reducida y MC2E.

	(1) MCO	(2) Primera etapa	(3) Forma reducida	(4) MC2E
=1 si recibió un proyecto de Eskom entre 1996 y 2001	-0.010* (0.006)			0.035 (0.065)
grad10		-0.077*** (0.027)	-0.003 (0.005)	
N	1816	1816	1816	1816
F efectivo (MOP)				8.26

La brecha entre MCO y MC2E para mujeres es enorme y va exactamente hacia donde predijimos en el ejercicio 1: si MCO estaba subestimando el efecto por el sesgo negativo del colapso comercial en las zonas cercanas a la red vieja, aislar variación exógena con la pendiente tenía que mover el estimador hacia arriba, y lo hace. Esa misma brecha, sin embargo, admite dos lecturas distintas. La primera es que el instrumento funciona: MCO estaba contaminado, MC2E corrigió el sesgo, y los 9,5 puntos son el efecto causal real. La segunda es que la brecha viene del propio instrumento, ya sea porque la pendiente es débil o porque viola exclusión, y bajo esa lectura MC2E también está sesgado y la brecha refleja ese sesgo en vez de la corrección del de MCO. Con esta tabla sola no podemos distinguir entre las dos lecturas: nos dice cuánto se movió el estimador, no si el movimiento fue por buena o mala razón. Para eso necesitamos el intervalo de Anderson-Rubin y la corrección t_F del ejercicio 4, y los chequeos de exclusión de los ejercicios 5 y 6.

El caso de varones ilustra por qué un punto estimado sin identificación no es un resultado. El MC2E da 0,035, un número grande en apariencia, pero la forma reducida es $-0,003$ y no es distinta de cero. Como el MC2E es esencialmente el cociente entre forma reducida y primera etapa, si el numerador es indistinguible de cero el cociente no dice nada. El intervalo de confianza del MC2E masculino va de $-0,09$ a $+0,16$, o sea que contiene el cero pero también contiene 16 puntos porcentuales, y no podemos concluir que el efecto sobre varones es más chico que el femenino, ni que es cero, ni que es igual al femenino.

4. La inferencia honesta

El estimador MC2E del ejercicio anterior tiene un intervalo de Wald de $[-0,012; 0,203]$ con $p = 0,083$, o sea que bajo el test clásico el efecto es significativo solo al 10 %. Pero ese intervalo asume que el instrumento es fuerte, y con un F efectivo de 8,26 estamos por debajo tanto del umbral clásico de Staiger y Stock (1997), que exige $F > 10$ como regla, como del umbral moderno de Lee et al. (2022), que exige $F > 104,7$ para poder confiar en la inferencia t estándar. Bajo cualquiera de las dos reglas, el instrumento es débil. En términos prácticos: cuando el instrumento es débil, el error estándar de Wald es engañosamente chico y el p -valor está subestimado, así que la significancia que aparece al 10 % no es la que parece. Dos herramientas robustas a instrumentos débiles nos permiten decir algo más honesto sobre el resultado principal del paper, y el Cuadro 3 las resume junto con el intervalo clásico como referencia.

Cuadro 3: Intervalos de confianza al 95 % para el efecto MC2E sobre empleo femenino.

Método	Intervalo	p -valor
Wald (clásico)	$[-0,012; 0,203]$	0,083
Anderson-Rubin	$[0,010; +\infty)$	0,034
t_F (Lee et al., 2022)	$[-0,114; 0,304]$	—

Antes de meternos en cada método, conviene marcar que los tres parten exactamente del mismo estimador puntual de 0,095 pero llegan a conclusiones contradictorias sobre significancia: Wald apenas rechaza al 10 %, AR rechaza cómodamente al 5 %, y t_F no rechaza a ningún nivel razonable. La razón es que cada método corrige un problema distinto de la inferencia estándar con instrumentos débiles.

(a) Anderson-Rubin

La idea intuitiva de Anderson-Rubin es distinta a la de Wald: en vez de estimar β y armar un intervalo alrededor del punto estimado, AR prueba muchos candidatos de β uno por uno y devuelve el conjunto de los que sobreviven al test. Ese conjunto es el intervalo AR. Formalmente, AR invierte una hipótesis nula $H_0 : \beta = \beta_0$ directamente sobre la forma reducida: bajo la nula, el residuo $\Delta y - \beta_0 T$ no debería estar correlacionado con la pendiente, y AR testea eso. La ventaja intuitiva es que la forma reducida es una regresión válida sin importar cuán fuerte sea la primera etapa, y por eso el test tiene tamaño correcto incluso bajo debilidad severa del instrumento. En nuestro caso AR aprovecha algo importante: la forma reducida es fuerte (el coeficiente de la pendiente sobre el empleo femenino es $-0,007$, significativo al 5 %), así que hay evidencia clara de que la pendiente predice el empleo femenino aunque no podamos estar seguros de cuán limpio es el canal de la electricidad. Por eso AR termina siendo incluso más fuerte que Wald y rechaza el cero al 5 % ($p = 0,034$), con un intervalo que arranca en 0,010 y se extiende hacia arriba. Bajo esta lectura, el resultado principal del paper sobrevive: hay evidencia estadística de que el efecto de electrificar sobre el empleo femenino es positivo y distinto de cero.

(b) t_F de Lee et al. (2022)

t_F toma un camino distinto: **mantiene el punto estimado MC2E** de 0,095 como está **y solo agranda el error estándar en proporción a cuán débil es la primera etapa**. La lógica es sencilla, porque si el instrumento es débil no podés confiar en que el error estándar clásico esté bien calibrado, así que lo inflás en función del F efectivo. Conviene aclarar también por qué t_F no reporta un p -valor: a diferencia de Wald y AR, que calculan primero un estadístico y su p -valor, t_F no hace un test formal sino que ajusta el error estándar y construye el intervalo directamente. La lectura práctica es una regla: dado el F, para rechazar al 5 % el $|t|$ tiene que superar cierto umbral, y como el F acá es 8,26 (muy lejos del 104,7 que Lee et al. exigen para no corregir), ese umbral es 3,82 en vez del 1,96 clásico. Nuestro $|t| = 1,73$ no lo alcanza, y por eso el intervalo resultante va de $-0,114$ a $+0,304$ y contiene el cero. Bajo esta lectura, el resultado principal del paper no sobrevive, ya que la significancia se cae cuando se corrige el error estándar por la debilidad del instrumento.

Comparación y qué reportar

Ninguno de los dos métodos es superior al otro, corrigen cosas distintas. AR dice que hay evidencia contra $\beta = 0$ porque la forma reducida es fuerte, y esa es una lectura válida. t_F dice que el punto estimado no es confiable dado que la primera etapa es débil, y esa también es una lectura válida. La conclusión del ejercicio no es que Dinkelman esté equivocada, sino que el resultado principal del paper es más frágil de lo que la Tabla 4 sugiere si uno lee solo los SEs de Wald. En un paper propio uno reportaría el intervalo de AR como principal, siguiendo la práctica de la autora, pero explicitando que bajo t_F el resultado pierde significancia.

5. La falsificación

El primer chequeo ataca directamente la historia alternativa del ejercicio 1: que la pendiente podría estar llegando al empleo por el canal de las rutas y no por la electricidad. **Si esa historia fuera cierta, al sacar las comunidades con ruta principal el resultado principal debería debilitarse**. El Cuadro 4, panel A, muestra lo contrario. Con la restricción `count_roads == 0` la muestra baja a 1792 comunidades, pero la primera etapa se refuerza: el coeficiente de la pendiente sobre el tratamiento pasa de $-0,077$ a $-0,087$ y el F efectivo sube de 8,26 a 10,43. **El instrumento no se debilita al bloquear el canal sospechado, todo lo contrario, funciona mejor cuando lo aislamos**. El MC2E en esta muestra es 0,069, algo menor al 0,095 original pero del mismo signo y orden, y el intervalo de Anderson-Rubin va de $-0,010$ a $0,222$, que contiene cómodamente al 0,095 del resultado principal. La historia alternativa que planteamos en el ejercicio 1 no explica el resultado del paper, y la hipótesis de la autora sale reforzada.

El segundo chequeo es más delicado. En las 373 comunidades de la muestra placebo la electrificación ocurrió antes de 1996, así que la pendiente no pudo haber afectado la asignación de proyecto durante el período estudiado. **Si el supuesto de exclusión vale, la forma reducida sobre el cambio en el empleo femenino en esa muestra debería ser esencialmente cero, porque el canal de la electricidad está apagado por construcción**. En la escala del paper (pendiente sin dividir por 10), el coeficiente placebo es $-0,001$, replicando exactamente la columna (1) de la Tabla 6. La lectura fácil sería concluir que el placebo es cero y que la exclusión queda validada, pero acá conviene

no comparar por significancia sino por magnitudes con sus intervalos, sobre todo con una muestra chica de 373 observaciones donde la potencia estadística es baja y un coeficiente puede parecer cero simplemente porque el error estándar es grande. El panel B del Cuadro 4 pone la forma reducida principal (ejercicio 3) al lado de la placebo, en la misma unidad. La principal es $-0,0007$ con intervalo $[-0,0014; -0,0001]$, y la placebo es $-0,001$ con intervalo $[-0,0036; +0,0015]$. Los dos intervalos se superponen fuertemente, y el punto placebo es incluso más grande en valor absoluto que el principal.

Este resultado es incómodo para la interpretación causal. Si en zonas donde la electrificación no puede ser el canal la pendiente sigue mostrando una asociación de tamaño similar con el empleo, entonces hay algo más entre pendiente y empleo que no es la electricidad. Y si ese canal alternativo también está operando en la muestra principal, parte del $-0,0007$ de la forma reducida no es efecto de electrificar, y por lo tanto el 0,095 del MC2E está sobreestimando el efecto real. El placebo no prueba que la exclusión esté rota, los intervalos son grandes y el punto estimado también es compatible con cero, pero deja una duda razonable: la comparación honesta no es contra cero, es contra la forma reducida principal, y en esa comparación el placebo no se distingue.

Cuadro 4: Chequeos de falsificación del instrumento.

	Coef. pendiente	Intervalo 95 %	F efectivo
<i>Panel A: Canal de las rutas (MC2E sobre T)</i>			
Muestra completa (ejercicio 3)	0,095	$[0,010; +\infty)$	8,26
Sin comunidades con ruta principal	0,069	$[-0,010; 0,222]$	10,43
<i>Panel B: Placebo (forma reducida sobre <code>mean_grad_new</code>)</i>			
Muestra principal (ejercicio 3)	$-0,0007$	$[-0,0014; -0,0001]$	—
Placebo (electrificadas antes de 1996)	$-0,001$	$[-0,0036; +0,0015]$	—

Los dos chequeos apuntan en direcciones distintas. El primero refuerza la hipótesis del paper, porque descarta uno de los canales alternativos más plausibles y muestra que el instrumento incluso mejora cuando se lo aísla del ruido de las rutas. El segundo introduce una duda razonable sobre la exclusión, no porque el placebo salga claramente distinto de cero, sino porque no logra distinguirse del efecto de la forma reducida principal.

6. La crítica

(a) Independencia

La pregunta del inciso es si la pendiente puede tratarse como si fuera asignada al azar entre comunidades, dados los controles. Esta es la primera condición que hay que chequear para creerle a cualquier instrumento: si la pendiente estuviera sistemáticamente ligada a otras características de las comunidades, entonces cualquier efecto que le atribuyamos podría venir en realidad de esas características y no de la pendiente en sí. La autora responde con las columnas (5) y (6) de la Tabla 1, donde regresa cada covariable de línea de base sobre la pendiente, primero sin controles y después incluyendo el resto de covariables y los efectos fijos de distrito. La lógica del chequeo es que, si algo se asigna al azar, no debería correlacionar con características preexistentes de las unidades. Si sí correlaciona, hay sesgo en el mecanismo de asignación.

La columna (5) muestra que sin controles la pendiente correlaciona con varias covariables: **las comunidades más planas tienden a ser más ricas, más densas y más pobladas por adultos con secundario**. Es esperable, porque la geografía influye en dónde se instala la gente y cómo se desarrolla económicamente, y por eso mismo la pendiente en crudo no puede tratarse como aleatoria. **La columna (6)**, en cambio, que es la especificación relevante para la estrategia del paper, **muestra que al agregar los controles y los efectos fijos de distrito casi todas esas correlaciones desaparecen**. Solo quedan diferencias menores en el sex ratio, la densidad de hogares y la fracción de varones con secundario, y el test conjunto de Bonferroni no rechaza al 1 %. O sea que dentro de un mismo distrito y controlando por las variables observables, una comunidad más plana no es sistemáticamente distinta de una más empinada en las características medidas. En ese sentido, la pendiente condicional a los controles se comporta como si fuera aleatoria, y ese es exactamente el supuesto que la estrategia del paper necesita.

Sin embargo, este chequeo tiene un techo importante: **solo balancea las variables que están en el dataset**. **No puede decir nada sobre variables no observadas, por lo que la evidencia es tan buena como se puede esperar sin un experimento** (las columnas (5) y (6) muestran que la pendiente balancea observables mejor que la propia asignación del proyecto), pero no es una prueba aleatoria, y ahí es donde vive el problema real de identificación.

(b) Exclusión

La historia alternativa que planteamos en el ejercicio 1 iba por el canal de las rutas, con la idea de que las comunidades planas tienen mejor acceso a rutas y eso podría afectar el empleo por vías ajenas a la electrificación, pero el ejercicio 5(a) desactiva esa historia con relativa contundencia: **al restringir la muestra a comunidades sin rutas principales, la primera etapa se refuerza en vez de debilitarse (F efectivo sube de 8,26 a 10,43)** y el intervalo de Anderson-Rubin del MC2E sigue conteniendo cómodamente el 0,095 del resultado principal, así que este chequeo apoya la exclusión. El ejercicio 5(b), en cambio, la debilita, porque el placebo sobre las 373 comunidades ya electrificadas antes de 1996 da un coeficiente de $-0,001$ (idéntico al que reporta la autora en la Tabla 6 columna (1)), pero al compararlo con la forma reducida principal de $-0,0007$ en la misma escala, resulta del mismo orden y con intervalos que se superponen. En una muestra donde la electricidad no puede ser el canal, la pendiente sigue mostrando el mismo tipo de asociación con el empleo, lo que sugiere que hay algún canal alternativo operando y que probablemente también esté operando en la muestra principal. La autora interpreta ese mismo coeficiente como un cero limpio y concluye que la exclusión vale, pero esa lectura por significancia es engañosa con solo 373 observaciones: comparando magnitudes con intervalos, la exclusión no queda blindada, y en balance la historia de las rutas queda descartada mientras que el placebo no permite defender la exclusión con la contundencia que la autora sugiere.

(c) Veredicto sobre los 9,5 puntos porcentuales

Con los tres números en la mano (F efectivo de 8,26, intervalo de Anderson-Rubin de aproximadamente $[0,01; +\infty)$ y coeficiente placebo de $-0,001$), el veredicto sobre los 9,5 puntos porcentuales de la Tabla 4 columna (8) se puede separar en dos dimensiones. **Sobre la identificación**, mi lectura es que el resultado está condicionalmente identificado pero con matices, porque el balance de

la columna (6) de la Tabla 1 sostiene la independencia y el chequeo de rutas descarta la historia alternativa más obvia, pero el placebo introduce una duda razonable sobre la exclusión: si hay un canal alternativo activo, parte de los 9,5 puntos no es efecto de electrificar. **Sobre la precisión**, el resultado está estimado con menos precisión de lo que la Tabla 4 sugiere, porque bajo Wald es significativo solo al 10 % y el ejercicio 4 mostró que bajo AR sobrevive al 5 % mientras que bajo t_F pierde significancia por la debilidad del instrumento. Combinando ambas dimensiones, no tomaría los 9,5 puntos como una cifra puntual sino como evidencia direccional de que la electrificación aumenta el empleo femenino en un orden de magnitud grande pero cuantitativamente frágil, y a la autora le pediría dos cosas: defender explícitamente por qué su $-0,001$ de la Tabla 6 columna (1) es evidencia de que la exclusión vale cuando ese mismo número no se distingue de la forma reducida principal, y reportar t_F junto con AR para que el lector vea el rango de fragilidad del resultado.